ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
имени М.В.ЛОМОНОСОВА»

Физический факультет

Кафедра оптики, спектроскопии и физики наносистем

БАКАЛАВРСКАЯ РАБОТА

Моделирование пластичности, зависящей от моментов импульсов, синаптического контакта на основе мемристора в задаче обучения импульсной нейронной сети

Выполнил студент
441"б" группы
Кулагин Всеволод Андреевич

_____

Научный руководитель:
к.ф.-м.н. Стремоухов Сергей Юрьевич, доцент

_____

Научный консультант:
к.ф.-м.н. Демин Вячеслав Александрович,
директор-координатор НИЦ «Курчатовский институт»

_____

Допущена к защите

Зав. кафедрой _____

Москва

2020

Аннотация

В данной работе объектом исследования являются импульсные нейронные сети, связями в которых являются мемристоры - элементы с пороговым резистивным переключением. Импульсные нейронные сети выгодно отличаются от классических нейронных сетей своей энергоэффективностью и использованием локальных правил обучения, что особенно важно для аппаратной реализации. На сегодняшний день известно много вариантов исполнения мемристора, поэтому необходимо исследование применимости различных мемристоров в аппаратной реализации ИНС. Целью данной работы является определение диапазона параметров мемристора, при которых ИНС на его основе работают корректно.

Для математического описания мемристора была выбрана модель Voltage ThrEshold Adaptive Model - VTEAM. Средствами библиотеки BindsNET, в которую была добавлена поддержка битреугольных импульсов, были проведены численные эксперименты для выяснения диапазона параметров модели, при которых веса связей тестовой нейронной сети сходятся к ожидаемым значениям. Получены обширные области сходимости, выяснено, что некоторые параметры не влияют на сходимость в данных условиях.

Оглавление

Используемые термины и сокращения **3**

Введение **4**

1 Мемристор и импульсные НС **7**

1.1 Мемристор 7

1.2 Математические модели мемристора 11

1.2.1 Модель дрейфующих ионов 12

1.2.2 Модель туннельного барьера Симмонса 16

1.2.3 TEAM и VTEAM 18

1.3 Импульсные НС 20

1.4 STDP 24

2 Методы работы **26**

2.1 Библиотека BindsNET 26

2.2 Численный эксперимент 27

3 Результаты **30**

Выводы **36**

Заключение **37**

Благодарности **37**

Список использованных источников **37**

Используемые термины и сокращения

1) **Мемристор** - пассивный энергонезависимый элемент памяти с пороговым характером переключения резистивного состояния.

2) **КМОП** - комплементарная структура металл-оксид-полупроводник.

3) **Синапс** - контакт между двумя нейронами, служащий для передачи нервного импульса.

4) **Кроссбар** - способ аппаратной реализации связей между двумя слоями нейронов. Представляет собой матрицу из мемристоров, соединенных нанопроволокой по столбцам и по строкам.

5) **ИНС** - импульсная нейронная сеть, т.е нейронная сеть, оперирующая временными последовательностями сигналов и использующая локальные правила обучения.

6) **STDP** - Spike-Timing Dependent Plasticity. Локальное правило обучения, при котором изменение веса зависит от интервала между имульсами.

7) **IF** - Integrate-and-Fire. Модель нейрона с пороговым значением потенциала, не учитывающая утечку.

8) **LIF** - Leaky Integrate-and-Fire. Модель нейрона с пороговым значением потенциала, учитывающая утечку.

9) **Пуассоновское распределение импульсов** - распределение импульсов, при котором вероятность того, что за интервал времени t не появилось ни одного импульса, равна $P(0,t) = e^{-\frac{t}{\tau}}$.

10) **Спайки**: **пост-спайк** и **пре-спайк** — сигналы, которыми обмениваются нейроны. Спайки распространяются по связям сети. Для синапса спайк пре-синаптического нейрона называется пре-спайком, а спайк пост-синаптического нейрона называется пост-спайком.

Введение

В области информационных технологий одним из приоритетных направлений является создание компьютеров нового поколения, нейросетей и искусственного интеллекта. Однако существующие аппаратные реализации нейросетевых алгоритмов (нейроморфные системы, НС) на традиционных архитектурах серьёзно уступают своим биологическим прототипам по производительности и энергопотреблению, что особенно проявляется при решении высокопараллельных задач, в том числе в области нейронных сетей [1,2]. Это диктует необходимость в разработке новых подходов, что выражается появлением в течение последних 10 лет ряда цифровых НС с весьма низким энергопотреблением и высокой производительностью [3,4]. В то же время, сложность реализации синаптической связи на КМОП элементах, при не достаточно большой плотности синаптических ячеек памяти [5], обусловила поиск новых материалов и способов исполнения синаптических весов.

Одной из многообещающих перспектив стала разработка мемристоров [6-8] – энергонезависимых сопротивлений с эффектом памяти субмикронных размеров, являющихся аппаратными аналогами (моделями) синапсов за счет воспроизведения свойства пластичности биологических прообразов (изменяемой эффективности передачи сигнала между нейронами) и выполняющих одновременно функции хранения и обработки информации. Было продемонстрировано большое количество прототипов систем, в основе которых лежит мемристивная структура с высокой плотностью размещения элементов на кристалле – «кроссбар», обладающих экстремально низким энергопотреблением и высокой скоростью работы [9,10]. В то же время, остается и ряд

недостатков: наличие паразитных токов различной природы в структуре типа «кроссбар», некоторые ограничения систем передачи данных между ядрами нейропроцессора, малоизученные подходы к созданию импульсных (спайковых) НС. Последние являются особенно важными, т.к. сегодня основным методом обновления весов в кроссбаре остается численный расчет с использованием методом обратного распространения ошибки, что требует немало вычислительных ресурсов и больших баз данных с обучающими выборками размеченных экспертами-людьми примеров. Импульсные сети основаны на более перспективных с точки зрения вычислительных мощностей и необходимых объемов размеченных данных локальных правилах обучения, использующих для обновления весов только информацию об активности и весах соседних (связанных друг с другом) нейронов. Одна из наиболее популярных версий локальных правил обучения реализуется при взаимном перекрытии спайков пре- и пост-синаптического нейронов. Данный механизм обозначается аббревиатурой STDP (от англ. «Spike-Timing Dependent Plasticity» - пластичность, зависящая от временной последовательности спайков), инспирирован правилами обучения в биологических нейронных сетях, а реализация его аналогов не раз была продемонстрирована на различных типах мемристоров [11,12].

Недавно была продемонстрирована принципиальная возможность работы аппаратной импульсной сети с мемристивными весами, оперирующей импульсами бипрямоугольной и биологически правдоподобной битреугольной формы, при правиле обучения, подобном STDP, а также предложены подходы организации схем нейросинаптического ядра для аппаратной реализации формальных и спайковых нейронных сетей на их основе [13].

Данная работа развивает подходы к реализации импульсных НС и посвящена определению возможных диапазонов параметров для физической реализации нейромофных устройств посредством моделирования поведения нейронов и синапсов при воздействии входных импульсов битреугольной формы и получения локальных правил их обучения.

Для этих целей для каждого начального значения синаптического веса при данных параметрах рассчитывается зависимость изменения веса связи от задержки между импульсами от связанных ей нейронов, после чего проверяется сходимость простых нейронных сетей, подчиняющихся этим правилам обучения, к ожидаемым результатам. Изменяя параметры, можно определить границы, в которых обеспечивается сходимость обучения спайковой нейронной сети на модельной задаче классификации.

1. Мемристор и импульсные НС

1.1 Мемристор

Мемристор — пассивный электротехнический элемент. Слово memristor образовано от сочетания английских слов memory и resistor, означающих «память» и «электрическое сопротивление» соответственно. В отличие от классических элементов, которые демонстрируют постоянный отклик на внешние сигналы, мемристор способен запоминать воздействия, приложенные к нему ранее, и, таким образом, может хранить информацию. После отключения напряжения в цепи мемристор не изменяет свое состояние. Впервые существование подобного элемента было предположено профессором Калифорнийского университета Леоном Чуа в 1971 [14]. Он выдвинул и математически обосновал гипотезу о том, что есть четвертый базовый элемент электрических цепей – наряду с индуктивностью, конденсатором и резистором. Чуа исходил из того, что должны быть соотношения, связывающие все четыре основные переменные электрических цепей: ток i, напряжение v, заряд q и магнитный поток ϕ . Всего таких соотношений может быть шесть. Пять из них хорошо известны. Заряд – это интеграл по времени от тока. Связь между напряжением и магнитным потоком определяется через закон электромагнитной индукции Фарадея. Напряжение и ток связаны через сопротивление R, заряд и напряжение – через емкость C, а магнитный поток и ток – через индуктивность L. Отсутствует шестое соотношение, связывающее поток и заряд. Чуа предположил, что эти величины связаны через “отсутствующий” элемент – мемристор, обладающий “мемристивностью” M: $d\phi = Mdq$ (рис.1). Отметим, что под потоком в данном случае

следует понимать интеграл от напряжения по времени. Чуа показал, что в общем случае мемристивность должна зависеть от q. Если воспользоваться соотношениями $d\phi = vdt$ и $dq = idt$, то можно записать связь между током и напряжением на мемристоре в виде:

$$v = M(q)i. \tag{1.1}$$

Очевидно, что в случае M = const мемристивность представляет собой обычное сопротивление и (1) превращается в закон Ома для участка цепи.

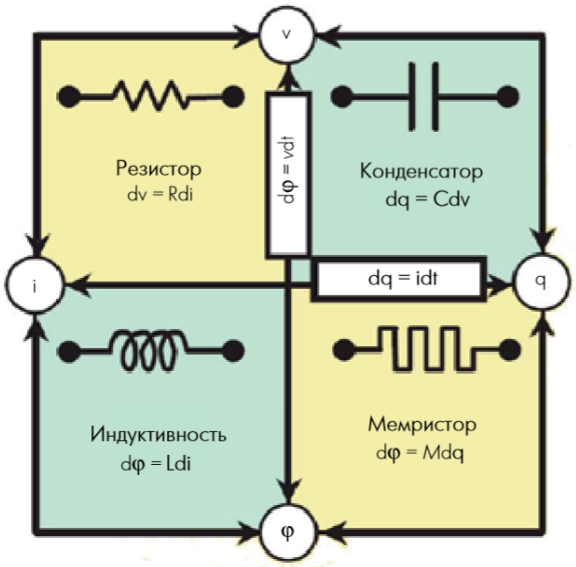

Рис. 1.1: Четыре базовых элемента электрической цепи.

Идеальный мемристор, описанный Л. Чуа, физически не реализуем, но существуют близкие по свойствам энергонезависимые элементы памяти с пороговым резистивным переключением, также называемые мемристорами [15].

Первый лабораторный образец мемристора был создан только в 2008 году в исследовательской лаборатории фирмы Hewlett-Packard коллективом учёных во главе с Р.С. Уильямсом. Мемристор, разработанный в HP группой Уильямса, представлял собой тонкий слой полупроводящего материала на основе TiO_2, размещенный между двумя металлическими контактами (рис.2) [6].

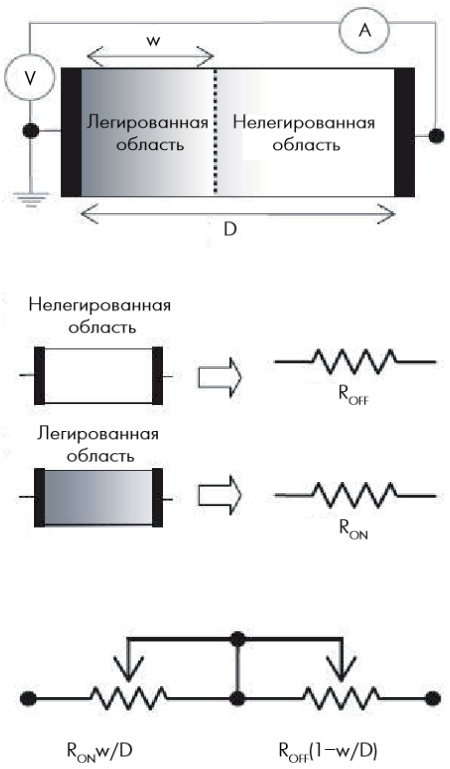

Рис. 1.2: Структура и эквивалентная цепь мемристора.

С одной стороны слоя диоксида титана в области шириной w находится легирующая примесь (положительные ионы). Свойства такого мемристора можно продемонстрировать на простой модели, основанной на механизме дрейфа ионов под действием приложенного напряжения. Полное сопротивление рассматриваемого устройства можно представить как сумму сопротивлений двух переменных резисторов, соединенных последовательно. Один из резисторов (проводящая область – недоокисленный слой Ti) имеет низкое сопротивление R_{on}, другой — намного более высокое сопротивление R_{off}. Когда к металлическим контактам прикладывается напряжение, заряженные ионы начинают дрейфовать и граница между двумя областями смещается. Если к мемристору приложено переменное синусоидальное напряжение определенной частоты, его вольтамперная характеристика (ВАХ) принимает гистерезисный вид. Таким образом, ВАХ мемристора имеет следующие основные особенности:

– при пропускании через мемристор биполярного периодического тока или напряжения ВАХ имеет гистерезисный характер . Важно отметить, что природа гистерезиса – внутреннее свойство мемристора, а не измерительной цепи;

– при увеличении частоты периодического сигнала амплитуда гистерезиса уменьшается и форма ВАХ вырождается в прямую линию, наклон которой зависит от амплитуды питающего сигнала.

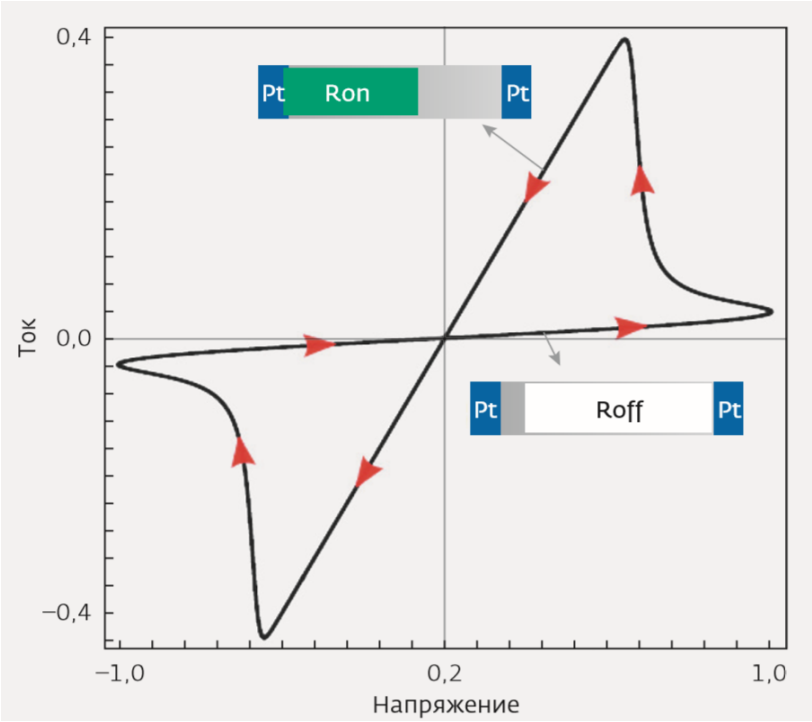

Рис. 1.3: Характерная ВАХ мемристора

В реальных мемристорах при достижении некоторого порогового значения напряжения происходит резкий переход в высокопроводящее состояние и наоборот, что можно назвать процессом включения/записи или выключения/стирания. По характеру пороговых переходов различают униполярные и биполярные мемристоры. В первых значения порогового напряжения имеют одинаковый знак, что ограничивает возможности их применения, во вторых знаки пороговых напряжений различны.

По особенностям механизма переключения мемристоры также

подразделяют на анионные и катионные, по типу основных подвижных частиц.

Помимо градиента электрического поля, движущими силами ионного транспорта могут служить градиенты концентрации частиц и температуры.

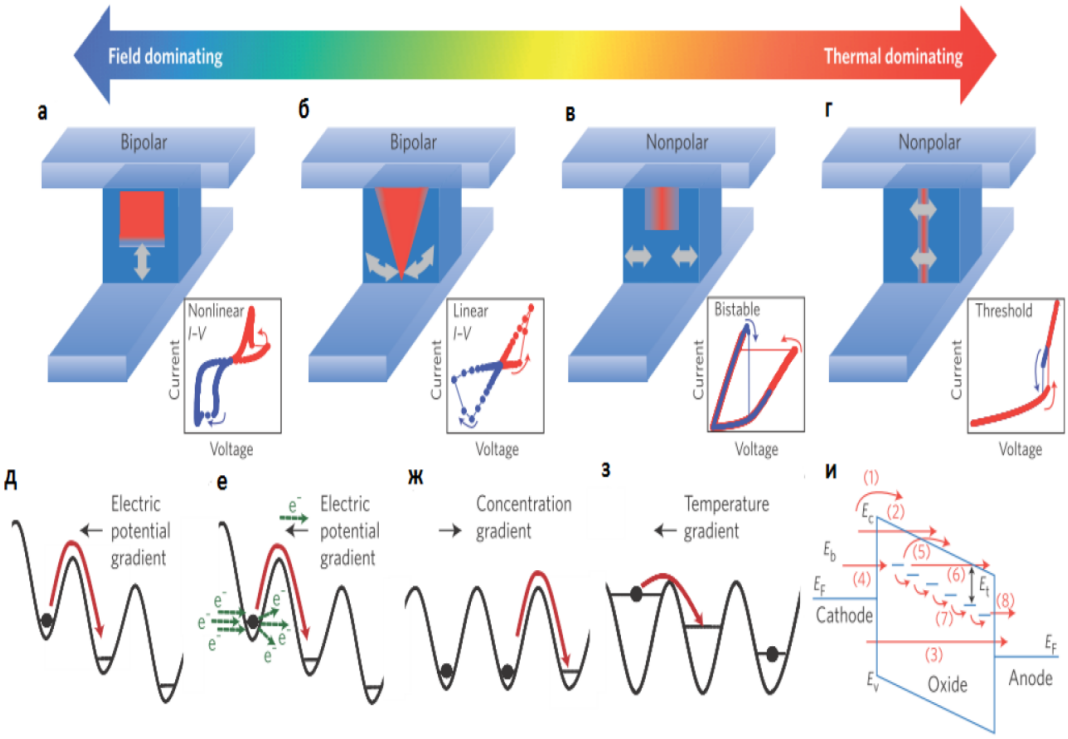

Рис. 1.4: Различные типы движущей силы ионного транспорта

Мемристивный эффект был получен на многих нанокомпозитах, например $(Co_{0.4}Fe_{0.4}B_{0.2})_x(LiNbO_3)_{1-x}$ [16].

1.2 Математические модели мемристора

Формально, интересующие нас макропараметры физической системы, проявляющей эффект мемристивнсти и состояние которой определяется интегралом прошедшего тока, описываются двумя уравнениями следующего вида:

$$\frac{d\omega}{dt} = f(\omega, i)$$

$$v(t) = R(\omega, i)i(t)$$

Здесь ω является переменной, описывающей главный физический параметр, отвечающий за проводимость мемристора. В частности, для реализации в качестве полупроводящего слоя, ω — линейный размер легированной области. $i(t)$ и $v(t)$ — соответственно ток, протекающий через мемристор и приложенное к нему напряжение, $R(\omega, i)$ — мемристивность, t — время.

Конкретная модель, которая может быть положена в основу виртуального элемента, должна удовлетворять целому ряду различных требований, зависящих, вообще говоря, от предполагаемого способа применения. Однако, можно выделить очевидные общие требования: точность, высокая скорость вычислений при компьютерной симуляции мемристора на основе данной модели, простота и интуитивность, гибкость и общность.

Проведем обзор нескольких подходов к математическому описанию мемристора.

1.2.1 Модель дрейфующих ионов

Простейшей моделью является модель линейного ионного дрейфа. Её представила команда HP для описания своего первого образца. Как уже было указано выше, мемристору, при предельном упрощении, может быть поставлена в соответствие эквивалентная схема из двух последовательно соединенных резисторов с сопротивлениями R_{on} и R_{off} характерными для обедненной и обогащенной кислородом областей соответственно. Предполагается, что вся структура имеет ширину D, а область с высокой концентрацией кислородных вакансий имеет ширину ω (рис. 2). Граница между этими областями может изменять своё

положение, в зависимости от величины и направления протекания заряда через устройство. Предположим, что проводимость является омической, имеет место линейный ионный дрейф в однородном поле, ионы имеют одинаковую среднюю подвижность μ_v во всех областях. Соотношения (2) и (3) могут быть записаны в виде:

$$\frac{d\omega}{dt} = \mu_v \frac{R_{ON}}{D} i(t) \tag{1.2}$$

$$v(t) = \left(R_{ON} \frac{\omega(t)}{D} + R_{OFF} \left(1 - \frac{\omega(t)}{D} \right) \right) i(t) \tag{1.3}$$

Сопротивление такого устройства зависит от отношения между значением динамической переменной $\omega(t)$, представляющей толщину слоя двуокиси титана (TiO_{2-x}) с недостаточным содержанием кислорода и толщиной устройства D. Данная модель предполагает, что вакансии имеют свободу передвижения по всей длине устройства. Но на практике это не так, поскольку вакансии должны замедляться у его границы. Если предположить что они беспрепятственно перемещаются вдоль всей структуры, это означает, что со временем это приведет к тому, что в устройстве не будет области, обогащенной кислородными вакансиями, а длина области с низким сопротивлением будет равна нулю, что невозможно. Аналогично, эта область не может занимать всю длину устройства. Чтобы преодолеть данную проблему, были введены оконные функции ($f(\omega)$ или $f(x)$), которые учитывают уменьшение подвижности ионов по мере приближения к границе устройства.

В [17] была предложена следующая оконная функция, на которую умножается выражение (4):

$$f(\omega) = 1 - \left(\frac{2\omega}{D} - 1 \right)^{2p} \tag{1.4}$$

Здесь p— положительное целое число, выступающее в роли параметра. На

рис. 5 показана эволюция оконной функции при изменении p. Видно, что при увеличении параметра нелинейность на границах проявляется всё в меньшей степени.

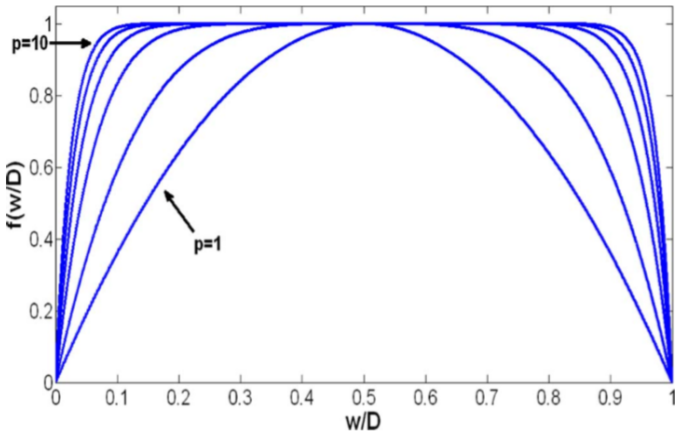

Рис. 1.5: [23] Оконная функция (6) для различных p

Оконная функция (6) имеет существенный недостаток для моделирования практических устройств, так как при достижении переменной ω нулевого значения, её величина уже не сможет измениться. Для предотвращения этой неточности моделирования была предложена другая оконная функция:

$$f(\omega) = 1 - \left(\frac{\omega}{D} - stp(-i)\right)^{2p},$$
$$stp(i) = \begin{cases} 1, \ i \geq 0 \\ 0, \ i < 0, \end{cases} \tag{1.5}$$

Где i—ток. Проблемами этих оконных функций являются невозможность их масштабирования и корректировки, максимальное значение такой функции может быть равно только единице. Чтобы преодолеть это ограничение, была предложена новая более гибкая оконная функция:

$$f(\omega) = j\left(1 - \left[\left(\frac{\omega}{D} - 0.5\right)^2 + 0.75\right]^p\right) \tag{1.6}$$

Её поведение при различных значениях j проиллюстрировано на рис.6, зависимость от p близка к представленной на рис.5. Эта оконная функция наиболее предпочтительна и будет подразумеваться далее.

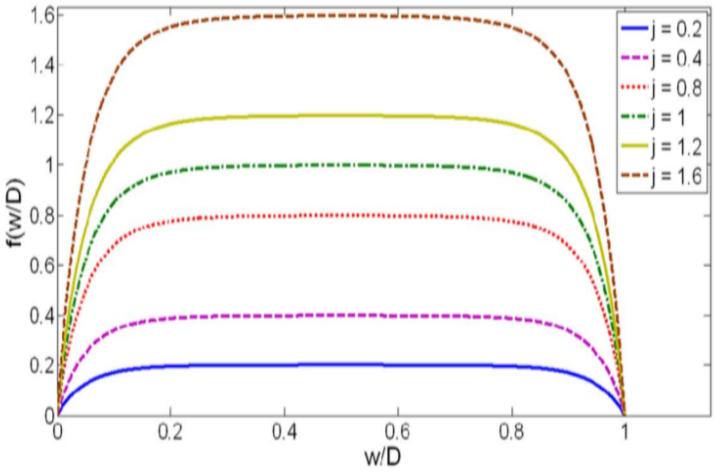

Рис. 1.6: [23] Оконная функция (8) для различных j

Приближение линейного ионного дрейфа довольно грубо. Существует также модель нелинейного ионного дрейфа, предполагающая, нелинейную зависимость между напряжением и границей между областями с разным сопротивлением. Кроме того, она учитывает асимметричное поведение ВАХ. Зависимость межу током и напряжением, а также положение границы между высокоомной и низкоомной областями определяется соотношениями:

$$i(t) = \omega(t)^n \beta \sinh(\alpha v(t)) + \chi[exp(\gamma v(t)) - 1] \tag{1.7}$$

$$\frac{d\omega}{dt} = af(\omega)v(t)^m \tag{1.8}$$

где $\alpha, \beta, \gamma, \chi, a$ и m являются произвольными параметрами, а параметр n определяет влияние положения границы на ток мемристора. В данной модели переменная ω нормирована и принимает значения в интервале от 0 до 1.

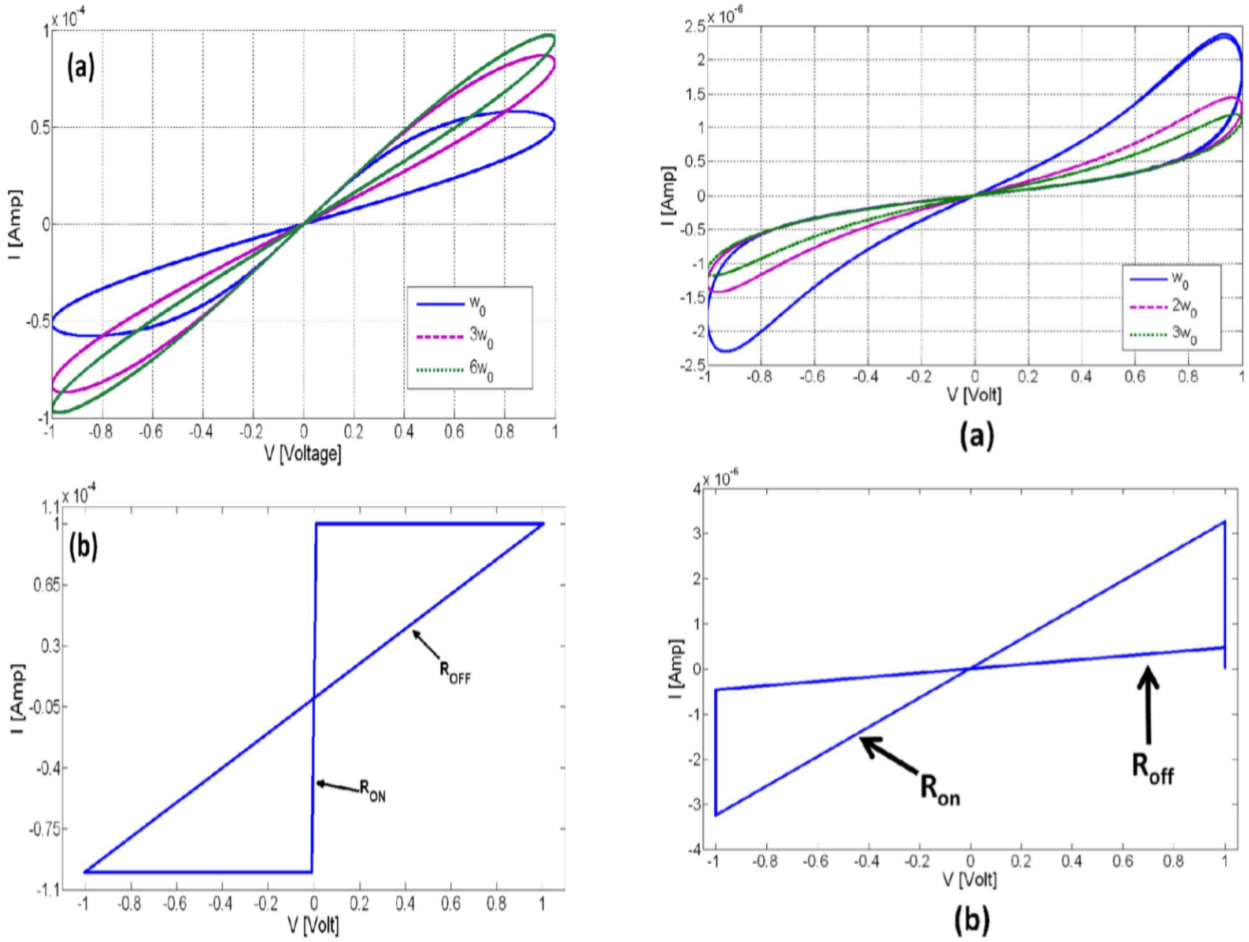

Рис. 1.7: [23] ВАХ мемристора, построенная с помощью модели дрейфующих ионов. Слева—приближение линейного дрейфа, справа—нелинейного. (a)— приложено синусоидальное напряжение трех разных частот, (b)— прямоугольный импульс

Во время состояния с низким сопротивлением кривая описывается гиперболическим синусом, а во время состояния с высоким сопротивлением кривая ведет себя подобно ВАХ p-n-перехода (экспоненциальная часть). Такая модель, в сравнении с линейной моделью, более точно описывает функционирование мемристора.

1.2.2 Модель туннельного барьера Симмонса

Еще более точная математическая модель была предложена лабораторией «HP» в 2009 году [18], где мемристор, в отличие от прошлых моделей, представляется как резистор в совокупности с туннельным барьером (рис.8). Здесь динамической переменной является не положение

границы между слоями двуокиси титана, а ширина туннельного барьера Симмонса. Взаимосвязь между током и напряжением выражена в виде уравнения, основанного на модели туннелирования Симмонса:

$$\begin{gathered} i(t) = A(x, v_g)\phi_1(v_g, x)exp\left(-B(v_g, x)\phi_1(v_g, x)^{\frac{1}{2}}\right) - \\ -A(x, v_g)(\phi_1(v_g, x) + e|v_g|)exp\left(-B(v_g, x)(\phi_1(v_g, x) + ev_g)^{\frac{1}{2}}\right) \end{gathered} \tag{1.9}$$

где

$$v_g = v - i(t)R_s \tag{1.10}$$

Важно, что внутреннее напряжение v не обязательно равно приложенному к устройству внешнему напряжению V. Изменение x описывается соотношением:

$$\frac{dx(t)}{dt} = \begin{cases} c_{off}\sinh\left(\frac{i}{i_{off}}\right)\exp\left[-\exp\left(\frac{x-a_{off}}{\omega_c} - \frac{|i|}{b}\right) - \frac{x}{\omega_c}\right], & i > 0, \\ c_{on}\sinh\left(\frac{i}{i_{on}}\right)\exp\left[-\exp\left(\frac{x-a_{on}}{\omega_c} - \frac{|i|}{b}\right) - \frac{x}{\omega_c}\right], & i < 0 \end{cases} \tag{1.11}$$

где $C_{off}, C_{on}, a_{off}, a_{on}, i_{off}, i_{on}$ и b являются параметрами. Параметры C_{on} и C_{off} влияют на скорость измененияx; значения i_{on} и i_{off} представляют собой пороговые значения токов, в пределах которых не происходит изменения толщины туннельного барьера; значения a_{off} и a_{on} соответственно определяют верхнюю и нижнюю границы для значения x, поэтому в данной модели нет необходимости в применении оконной функции. Эта модель является наиболее точной математической моделью мемристора, но она имеет некоторые существенные недостатки, такие как высокая сложность и отсутствие явной связи между током и напряжением. Помимо этого, данная модель не является общей, так как она описывает только определенный тип мемристора.

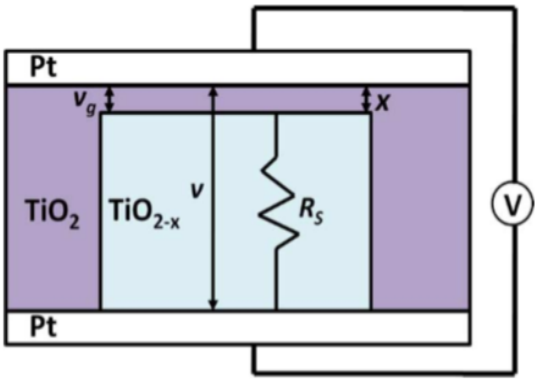

Рис. 1.8: [23] x — ширина оксидной области, V — приложенное к электродам напряжение, v_g —разность потенциалов в барьерной области, v —разность потенциалов между краями структуры, R_s — сопротивление резистивной области

1.2.3 TEAM и VTEAM

TEAM—ThrEshold Adaptive Model. В рамках данной модели предполагается отсутствие изменения переменных параметров модели в пределах определённого порога и используется полиноминальная зависимость между током мемристора и толщиной туннельного барьера вместо экспоненциальной. Зависимость производной толщины туннельного барьера от тока моделируется путём умножения двух функций, одна из которых является функцией тока, а другая зависит от переменной x. Закон изменения x:

$$\frac{dx(t)}{dt} = \begin{cases} k_{off}\left(\frac{i(t)}{i_{off}} - 1\right)^{a_{off}} f_{off}(x), & 0 < i_{off} < i, \\ 0, & i_{on} < i < i_{off}, \\ k_{on}\left(\frac{i(t)}{i_{on}} - 1\right)^{a_{on}} f_{on}(x), & i < i_{on} < 0 \end{cases} \tag{1.12}$$

Здесь $k_{off} > 0, k_{on} < 0, a_{off}$, и a_{on} константы, x толщина эффективного барьера, $f_{on}(x)$ и f_{off}, вообще говоря не равные друг другу, имеют вид одной из оконных функций, описанных выше.

Соотношение между током и напряжением можно ввести подобно принятому в линейной модели дрейфующих ионов:

$$i(t) = \left[R_{on} + \frac{R_{off} - R_{on}}{x_{off} - x_{on}}(x - x_{on})\right]^{-1} v(t) \tag{1.13}$$

Либо, для приближения к модели барьера Симмонса, ввести экспоненциальную зависимость:

$$v(t) = i(t) R_{on} e^{(\frac{\lambda}{x_{off}} - x_{on})(x - x_{on})} \tag{1.14}$$

где

$$\frac{R_{off}}{R_{on}} = e^{\lambda} \tag{1.15}$$

В последнем случае, как видно на рис.9, TEAM дает результаты, очень близкие к весьма точной модели туннельного барьера.

VTEAM [17] весьма схожа с TEAM, с той разницей, что переменная x здесь ставится в явную зависимость не от тока, а от напряжения, что делает модель более удобной для практического использования. Соотношение (14) примет вид:

$$\frac{dx(t)}{dt} = \begin{cases} k_{off}\left(\frac{v(t)}{v_{off}} - 1\right)^{A_{off}} f_{off}(x), & 0 < v_{off} < v, \\ 0, & v_{on} < v < v_{off}, \\ k_{on}\left(\frac{v(t)}{v_{on}} - 1\right)^{A_{on}} f_{on}(x), & v < v_{on} < 0 \end{cases} \tag{1.16}$$

$$f_{off} = exp(-e^{\frac{x - a_{off}}{x_c}}),$$

$$f_{on} = exp(-e^{\frac{a_{on} - x}{x_{c_on}}})$$

Сопротивление получаем по формуле:

$$R = R_{on} e^{\lambda \frac{x - x_{on}}{x_{off} - x_{on}}}, \text{ где } \lambda = ln(\frac{R_{off}}{R_{on}})$$

Как видно на рис.9, VTEAM с экспоненциальным соотношением между током и напряжением неплохо аппроксимирует ВАХ реальных мемристоров из различных материалов (для каждого материала свой набор параметров $k_{on/off}, \alpha_{on/off}, x_{on/off}, R_{on/off}$).

В данной работе будет использоваться именно модель VTEAM, в силу своей простоты, общности и гибкости.

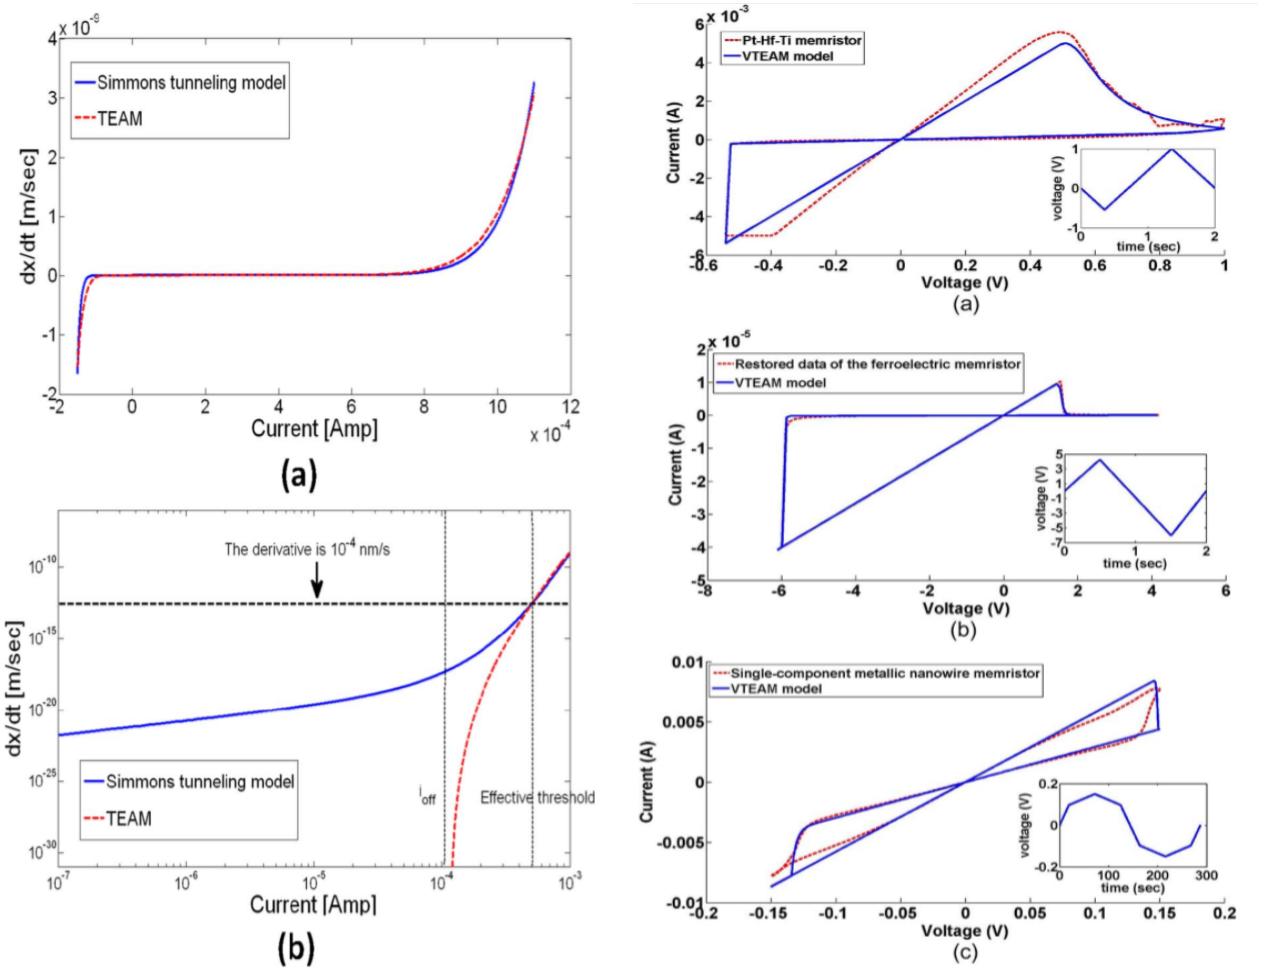

Рис. 1.9: [23] Слева— сравнение TEAM и модели барьера Симмонса, справа— сравнение VTEAM и реальных устройств.

1.3 Импульсные НС

Импульсная нейронная сеть (или спайковая нейронная сеть) — третье поколение искусственных нейронных сетей [21], которое отличается от бинарных (первое поколение) и частотных/скоростных (второе поколение)

ИНС тем, что в нем нейроны обмениваются короткими (у биологических нейронов — около 1-2 мс) импульсами одинаковой амплитуды (у биологических нейронов — около 100 мВ). Является самой реалистичной, с точки зрения физиологии, моделью ИНС.

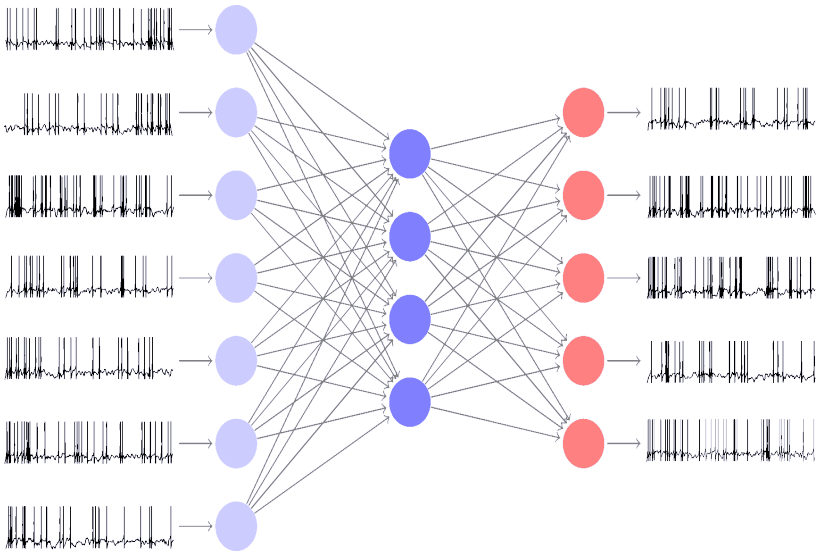

Рис. 1.10: Наглядная схема импульсной НС

Сеть получает на входы серию импульсов и выдаёт импульсы на выходе. Информация кодируется временными последовательностями импульсов.

В каждое мгновение каждый нейрон имеет некоторое значение потенциала (аналог электрического потенциала у биологических нейронов) и, если это значение превышает пороговое, то нейрон посылает одиночный импульс, после чего его собственное значение потенциала падает до уровня ниже среднего значения. При выведении из состояния равновесия потенциал нейрона начинает плавно стремиться к среднему значению. Допустимо рассмотрение нейрона, имеющего пороговое значение потенциала, с учетом утечки (Leaky Integrate-and-Fire - LIF model) и без её учета (Integrate-and-Fire - IF). Для IF нейронов справедливо (- емкость):

$$I(t) = C\frac{dV}{dt}$$

Когда на вход подаётся ток, разность потенциалов на мембране возрастает со временем, пока не достигает некоторого значения V_{th}, при котором происходит скачкообразное изменение потенциала на выходе и напряжение сбрасывается до остаточного потенциала. После этого алгоритм повторяет работу с начала, пока опять не накопит энергии на следующее срабатывание. Такая схема имеет существенный недостаток — бесконечно большое линейное возрастание частоты срабатывания при линейном увеличении входного тока, что возможно только в абсолютно идеальных условиях без утечек.

Уточнить модель позволяет введение рефрактерного периода t_{ref}, который ограничивает частоту срабатывания, запрещая срабатывание в течение некоторого времени после возникновения потенциала действия. Это аналог процесса реабилитации, у биологических нейронов он длится 2-30 мс. Частота срабатывания в таком случае может быть описана как функция от постоянного тока следующей формулой:

$$f(I) = \frac{I}{CV_{\mathrm{th}} + t_{\mathrm{ref}} I}$$

Недостаток этого подхода заключается в проявлении свойств независимой от времени памяти. Если модель получает некий заряд, недостаточный для срабатывания, она сохраняет его до следующего срабатывания. Если срабатывания не произойдёт — напряжение будет сохраняться вечно, что не соответствует процессам, наблюдаемым в реальной мембране.

Дальнейшее усовершенствование вышеописанной модели решает указанный недостаток вечной памяти путём введения концепции утечки. Метод симулирует диффузию ионов, происходящую на поверхности мембраны в случае недостижения условий для генерации потенциала действия. Улучшенная подобным образом модель может быть описана

следующей формулой:

$$I(t) - \frac{V(t)}{R} = C\frac{dV(t)}{dt}$$

где R — значение электрического сопротивления мембраны. Теперь, чтобы сгенерировать потенциал действия, необходимо, чтобы значение тока на входе превысило некоторый порог $I_{th} = V_{th}/R$. Иначе происходит утечка, аннулируя любые изменения потенциала. Частота срабатывания принимает следующий вид:

$$f(I) = \begin{cases} 0, & I \leq I_{\text{th}} \\ [t_{\text{ref}} - RC\log(1 - \frac{V_{\text{th}}}{IR})]^{-1}, & I > I_{\text{th}} \end{cases}$$

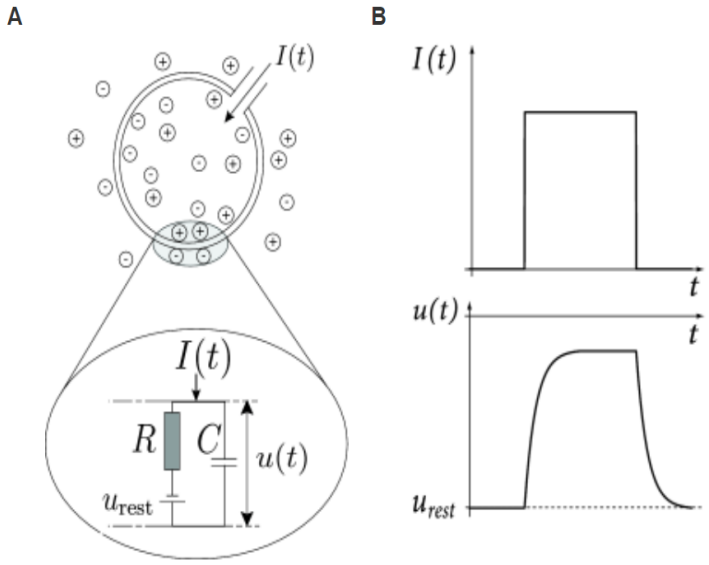

Рис. 1.11: [22] A - Нейрон, окруженный мембраной, участок которой можно представить как конденсатор с параллельным сопротивлением. B - отклик потенциала мембраны на прямоугольный сигнал.

В данной работе все численные эксперименты будут проводится с использованием LIF модели нейронов.

Импульсные нейронные сети — вид нейронных сетей, наиболее подходящий для аппаратной реализации, так как могут использовать исключительно локальные правила обучения, основывающиеся на правиле Хебба, которое применительно к ИНС можно сформулировать так: Если

пре- импульс предшествует постимпульсу, то связь укрепляется, если наоборот — то ослабляется. Здесь пре- импульс означает импульс от нейрона, предшествующего связи, пост — следующего за связью.

В качестве синаптической связи в аппаратной реализации ИНС могут быть использованы мемристоры, весом связи будет служить его проводимость. Существуют прототипы систем, в основе которых лежит мемристивная структура с высокой плотностью размещения элементов на кристалле – «кроссбар», обладающих низким энергопотреблением и высокой скоростью работы.

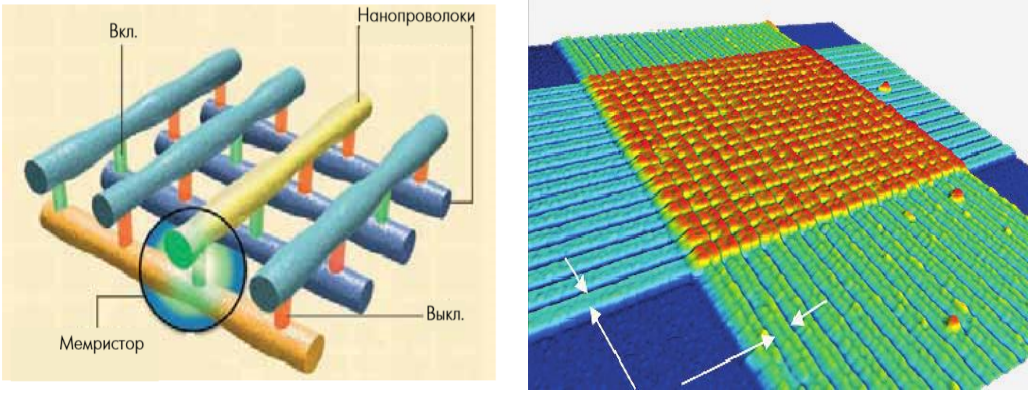

Рис. 1.12: Слева схематичное изображение кроссбара, справа реальное устройство

1.4 STDP

Spike-Timing Dependent Plasticity является одним из вариантов хеббовского локального правила обучения. Оно представляет собой закон, по котрому изменение веса зависит от задержки между пре- и пост- импульсами. Идеализированный закон STDP представляет собой экспоненту:

$$W(\Delta t) = \begin{cases} A_+ exp(-\frac{-\Delta t}{\tau_+}), & \Delta t > 0 \\ -A_- exp(-\frac{\Delta t}{\tau_-}), & \Delta t < 0 \end{cases}$$

Где Δt - задержка между импульсами (отрицательная задержка означает, что пост- спайк пришел раньше пре- спайка), A_+, A_-, τ_+, τ_- - константы. Однако, реальные STDP лишь приблизительно похожи на экпоненты. Кроме того, на самом деле такие законы различны для каждого начального значения веса. Ниже представлены примеры графиков, полученных в рамках настоящей работы для модели мемристора VTEAM при прохождении встречных битреугольных импульсов (вес нормирован на 1). Каждый раз, когда через связь проходит пара импульсов, ее вес меняется в соответствии с построенной для нее STDP зависимостью. При этом важно, чтобы один импульс не мог переключить состояние мемристора (R_{off}/R_{on}), поэтому их амплитуды немного меньше порогового v_{th} из (1.18).

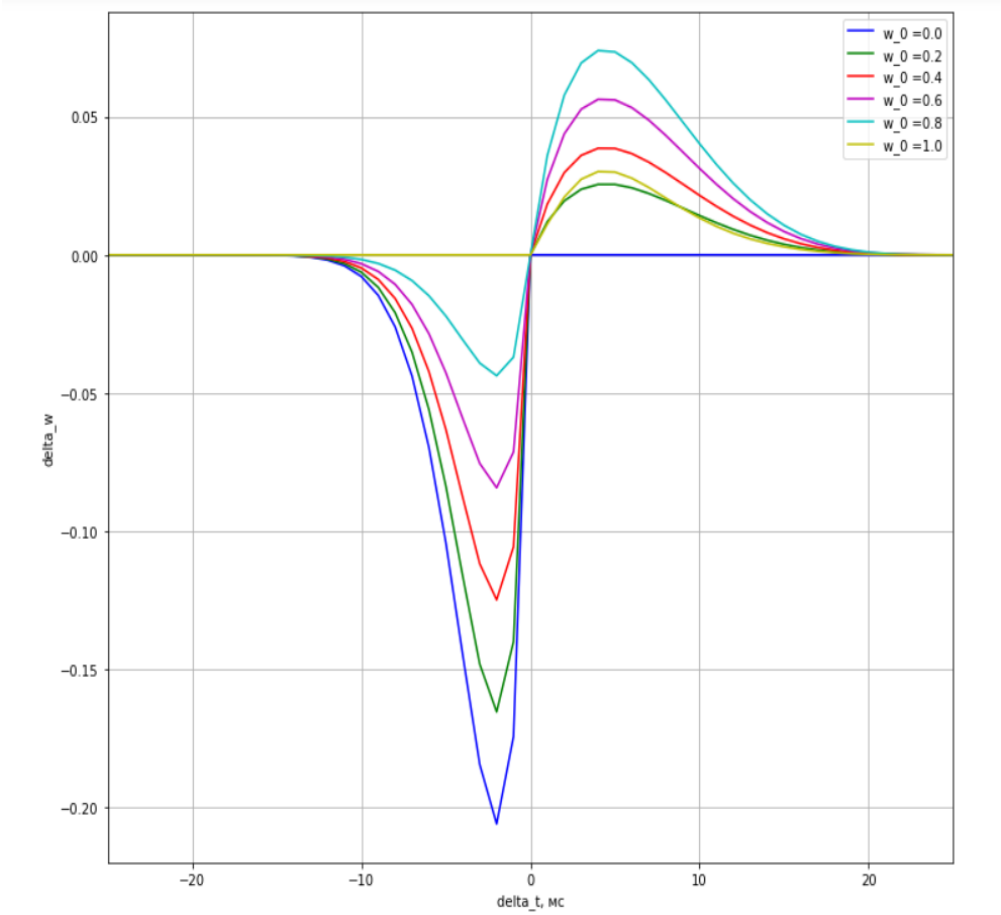

Рис. 1.13: Кривые STDP для разных начальных весов. По абсциссе задержка между импульсами, по ординате изменение веса.

2. Методы работы

2.1 Библиотека BindsNET

Как уже говорилось выше, данная работа ставит перед собой задачу исследовать сходимость обучения импульсных нейронных сетей с синаптическими связями, подчиняющимися модели VTEAM. Для симуляции ИНС можно воспользоваться библиотекой BindsNET [19]. Она написана на языке Python с использованием пакета для работы с тензорами PyTorch. Библиотека позволяет ставить эксперименты с НС любой архитектуры. Стандартным правилом обучения является классическое экспоненциальное STDP с настраиваемыми параметрами. Настроить также можно время эксперимента, начальные веса, входной сигнал. В рамках данной работы библиотека была модифицирована для нужд задачи. Помимо незначительных, есть два важных изменения: добавление поддержки биологически правдоподобных битреугольных импульсов (ранее присутствовали только дельта- импульсы), а также возможность вводить правила обучения из заранее подготовленной базы данных, а именно базы зависимостей STDP.

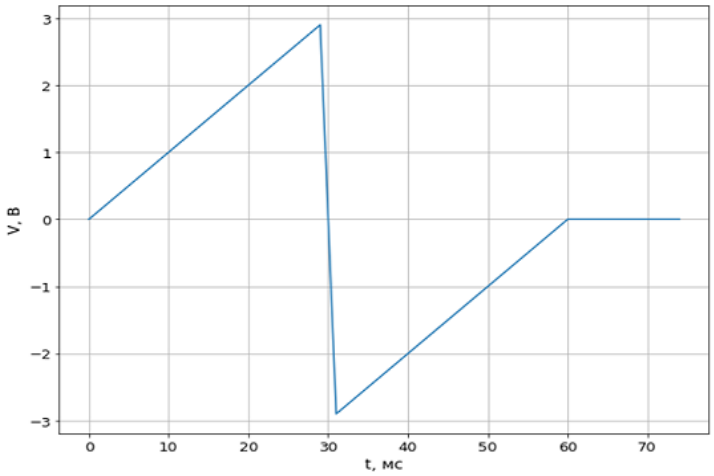

Рис. 2.1: Битреугольный импульс, используемый в симуляции.

2.2 Численный эксперимент

Численные эксперименты ставились следующим образом. Средствами BindsNET создавалась тестовая сеть из двух входов и двух выходов. Все нейроны одного слоя соединены со всеми нейронами другого, перекрестные веса инициализируются меньшими значениями, чем прямые (прямой вес соединяет, например, первый нейрон входного слоя с первым нейроном выходного) . На каждый вход по очереди подавались последовательности, подчиняющиеся распределению Пуассона. Так как информация кодируется средней частотой импульсов, то это соответствует задаче классификации двух объектов — векторов (1,0) и (0,1). Если первый нейрон реагирует на первый класс, а второй на второй класс, то ожидаемый исход эксперимента - веса прямых связей стремятся к 1, а веса перекрестных к 0. В этом случае считаем сеть сходящейся при данных параметрах, в противном случае — нет. Для оценки сходимости введена норма: $N = 2 * (\overline{w} - 0.5)$, где $\overline{w}$ - среднее значение весов в конце цикла. С учетом продолжительности каждого эксперимента (6000 мс) значение нормы -0.6 соответствует стремлению всех весов к 0, а значение около 0.1 - сходимости. За большее время эти значения составили бы -1 и 0 соответственно, но в силу большого времени, затрчиваемого на эксперимент, и того, что качественный результат заметен быстрее, было решено остановится на 6000 мс. Тестовая сеть обучалась по закону STDP, построенному при подаче двух битреугольных импульсов с различными задержками от -60 мс до 60 мс на модель мемристора VTEAM. Так как STDP зависит от текущего веса, строились 100 кривых STDP для каждого возможного значения нормированной проводимости с шагом 0.01.

Были заранее определены значения параметров, при которых

сходимость тестовой сети была воспроизводимой (они приведены в таблице). Пороговые напряжения v_{on} и v_{off} во всех экспериментах равнялись -3.3 В и 3.3 В соответственно, параметры $x_{on} = 0$ м и $x_{off} = 3 * 10^{-6}$м определяют линейные размеры мемристора, $x_{on} < x < x_{off}$. Отношение сопротивлений двух режимов мемристора: $\frac{R_{off}}{R_{on}} = 65$.

Параметр	Значение
A_{on}	5
A_{off}	13
K_{on}	$-1.32 * 10^{-6} \frac{\text{м}}{\text{с}}$
K_{off}	$5 * 10^{-6} \frac{\text{м}}{\text{с}}$
a_{on}	$1.5 * 10^{-6}$м
a_{off}	$1.2 * 10^{-9}$м
x_{c_on}	10^{-6}м
x_c	100 м

Проводимость каждой связи, при отсутствии подкреплений, уменьшается со скоростью $5 * 10^{-5} \frac{\text{См}}{\text{с}}$. Генерация нейроном импульса происходит при достижении 22 В, после чего напряжение на нейроне падает до 0.

В цикле в широком диапазоне изменялись значения одного из параметров (1.18). Остальные параметры при этом оставались равными значениям из таблицы. Для каждого значения варьируемого параметра строился набор кривых STDP для различных текущих весов и проверялась сходимость тестовой сети с этим правилом обучения. Такой эксперимент был проведен для параметров $A_{on}, A_{off}, K_{on}, K_{off}, a_{on}, a_{off}, x_{c_on}, x_c$.

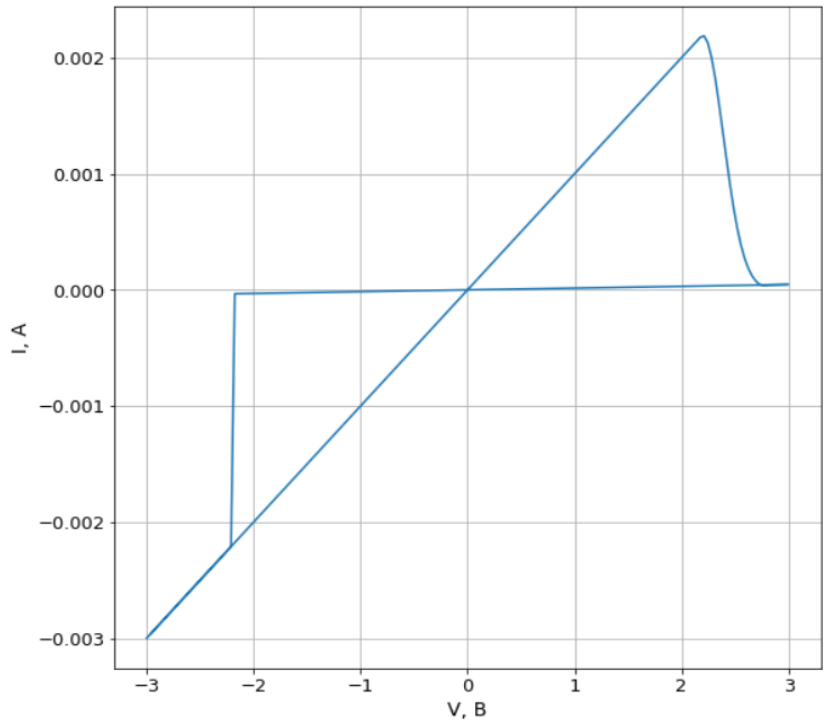

Рис. 2.2: ВАХ мемристора, описываемого моделью VTEAM, при параметрах, приведенных в таблице.

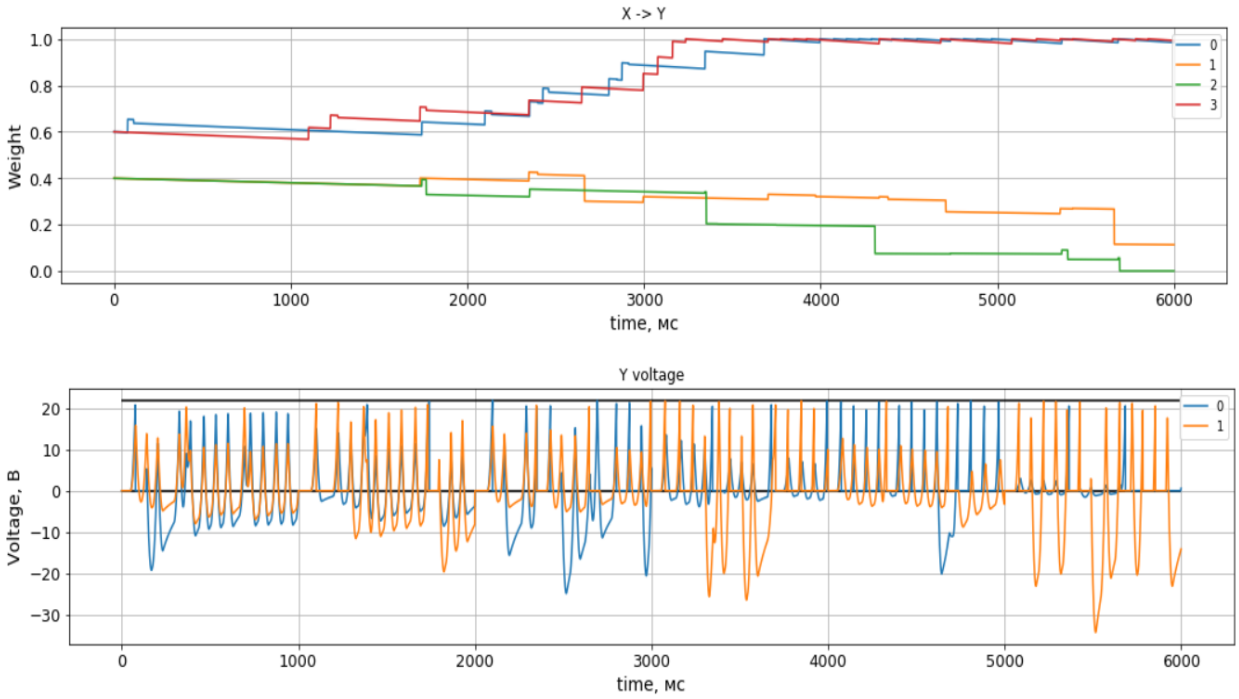

Рис. 2.3: Пример поведения весов связей и напряжений на выходных LIF нейронах во время эксперимента

3. Результаты

В данном разделе представлены графики зависимости нормы от различных параметров модели VTEAM при фиксированных остальных параметрах (рис. 3.2 - 3.9), а также таблица границ сходимости сети. В таблице представлены приблизительные границы, так как переходные зоны нестабильны и сходимость в них зависит от конкретной входной последовательности имупульсов. На графике для A_{on}, например, переходная область находится в диапазоне от 1 до 10. В указанных в таблице областях сходимость воспроизводима.

Параметр a_{on}, входящий в оконную функцию f_{on} из (1.18), обеспечивает существование областей значений x, в которых производная $\frac{dx(t)}{dt}$ отлична от нуля при $v < v_{on}$, лишь тогда, когда он находится приблизительно в границах мемристора, определяемых x_{on} и x_{off}, что следует из поведения f_{on}, представленного на рисунке ниже. Именно поэтому при превышении x_{off} положительная часть STDP исчезает и сеть перестает сходиться, что будет видно на соответствующем графике.

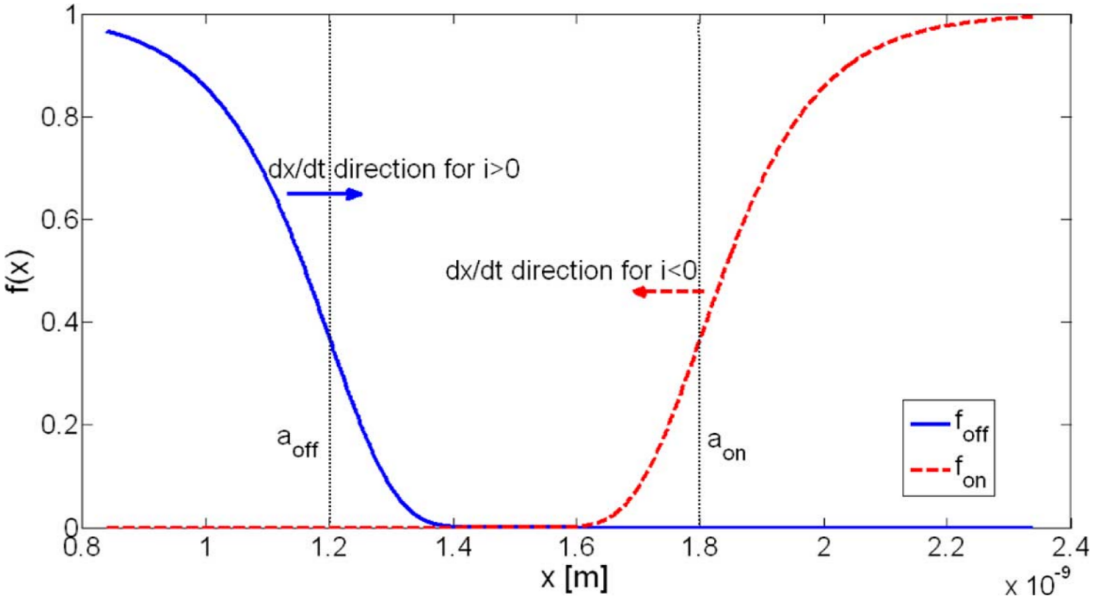

Рис. 3.1: [23] Поведение оконных функции.

Вышесказанное относится и к a_{off} при $v > v_{off}$. Но, как будет видно, параметры a_{off} и x_c не влияют на сходимость, что обусловлено тем, что они определяют реакцию связи только на импульсы с отрицательной задержкой. Так как входные нейроны, как и все, имеют период рефрактерности (60 мс), что больше характерного времени затухания кривой STDP, значительное отрицательное приращение веса нейрона (на величину которого влияют эти параметры) является относительно редким событием. Даже при полном отсутствии отрицательных приращений сеть может сойтись, так как веса, как говорилось выше, не только реагируют на импульсы, но и безусловно уменьшаются с небольшой скоростью.

Так как параметр K_{off} входит в выражение для $\frac{dx(t)}{dt}$ как множитель, то, несмотря на редкость отрицательных приращений, он может сделать их достаточно большими для того, чтобы сеть разошлась. Поэтому он, как и другие оставшиеся параметры, влияет на сходимость.

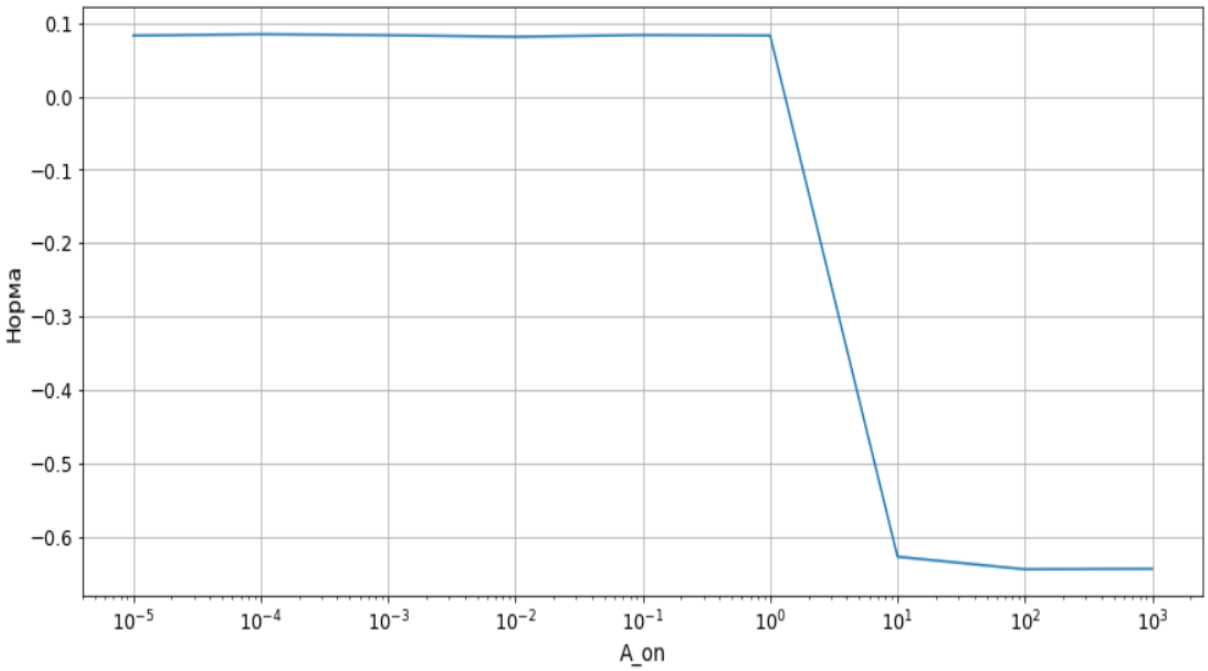

Рис. 3.2: Сходимость сети в зависимости от A_{on} . Норма вблизи значения 0,1 соответствует сходимости к ожидаемым значениям весов; норма, отличная от 0.1, соответствует расходимости задачи.

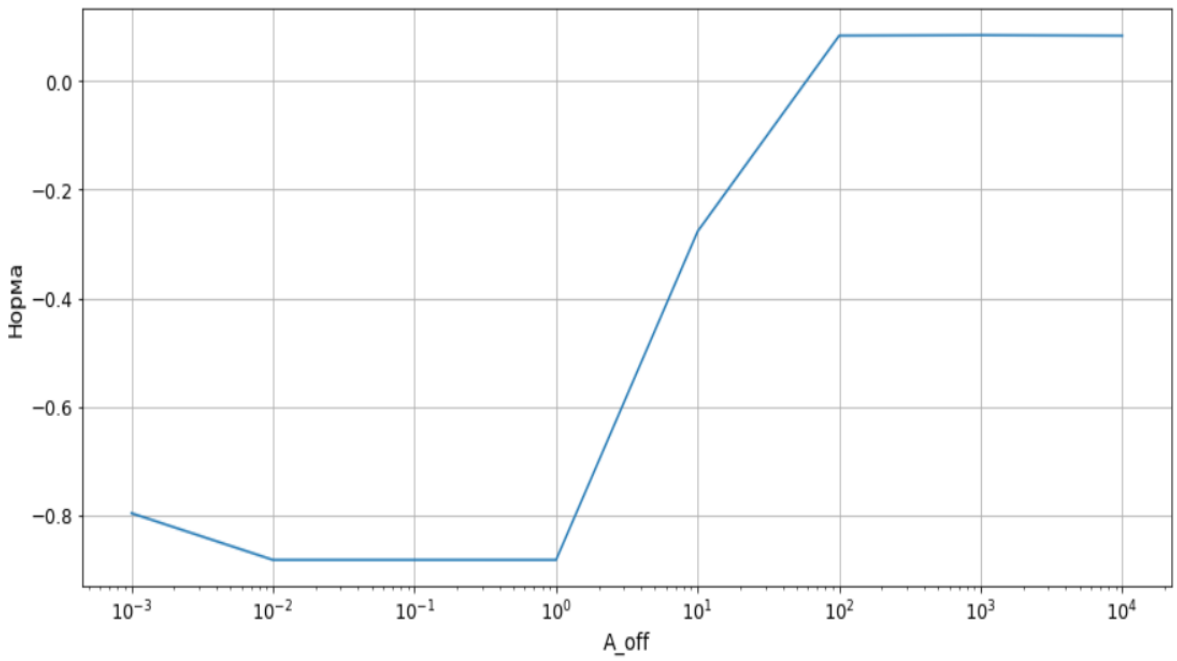

Рис. 3.3: Сходимость сети в зависимости от A_{off}. Норма вблизи значения 0,1 соответствует сходимости, норма, отличная от 0.1, соответствует расходимости.

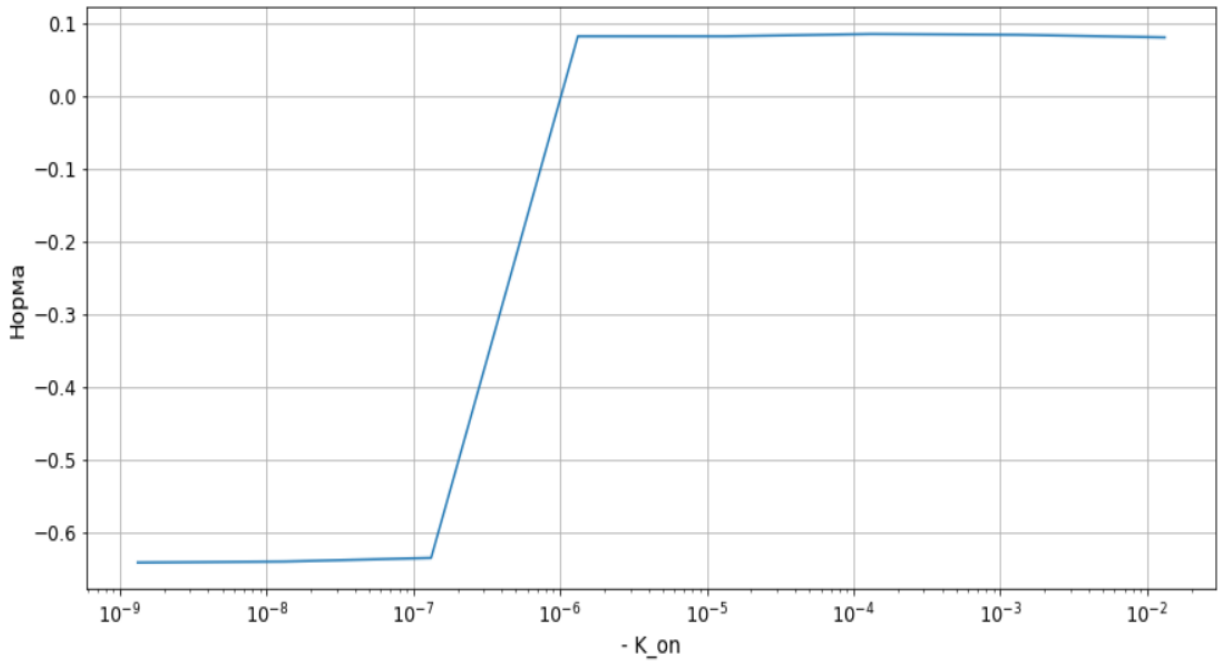

Рис. 3.4: Сходимость сети в зависимости от K_{on} . Норма вблизи значения 0,1 соответствует сходимости, норма, отличная от 0.1, соответствует расходимости.

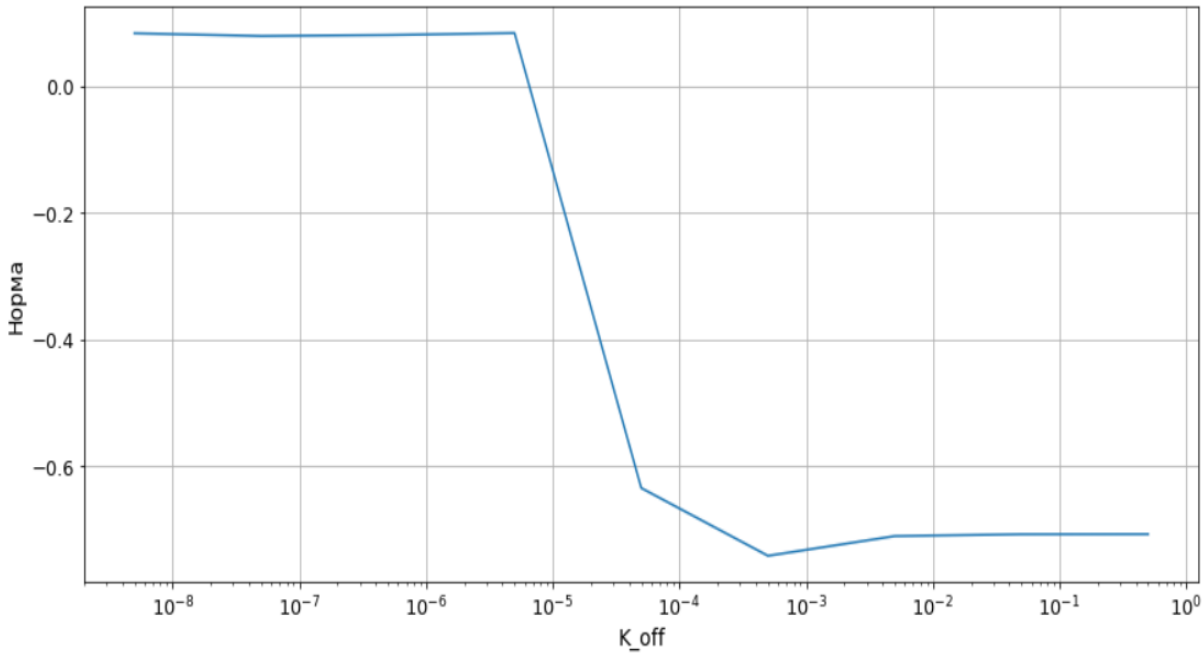

Рис. 3.5: Сходимость сети в зависимости от K_{off} . Норма вблизи значения 0,1 соответствует сходимости, норма, отличная от 0.1, соответствует расходимости.

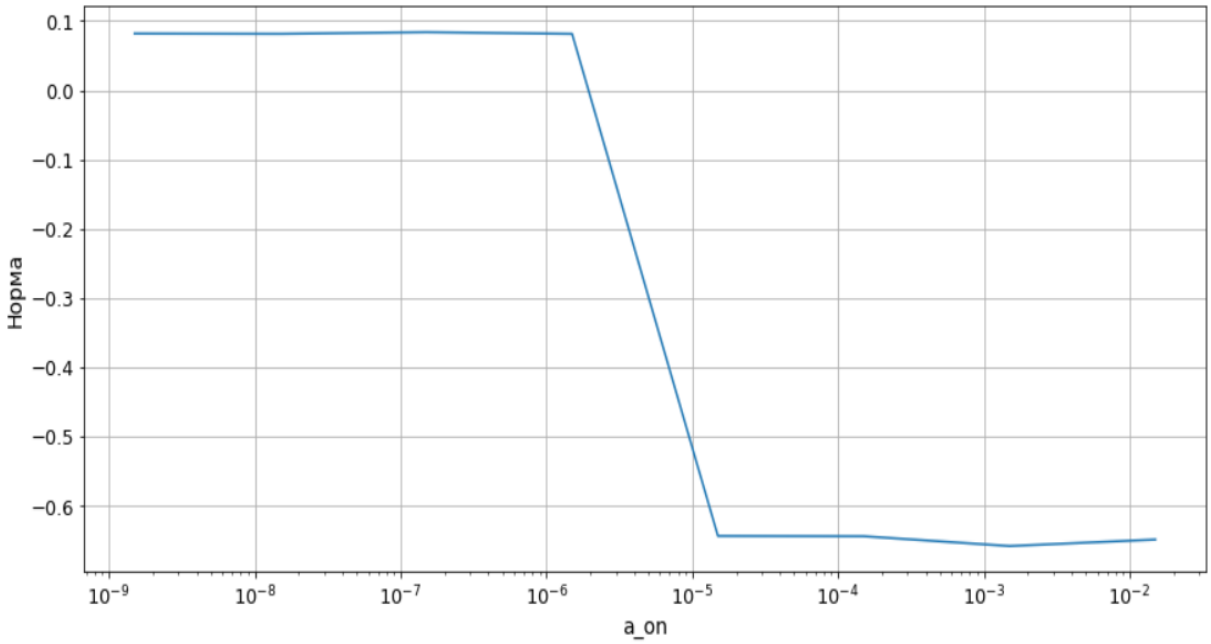

Рис. 3.6: Сходимость сети в зависимости от a_{on} . Норма вблизи значения 0,1 соответствует сходимости, норма, отличная от 0.1, соответствует расходимости.

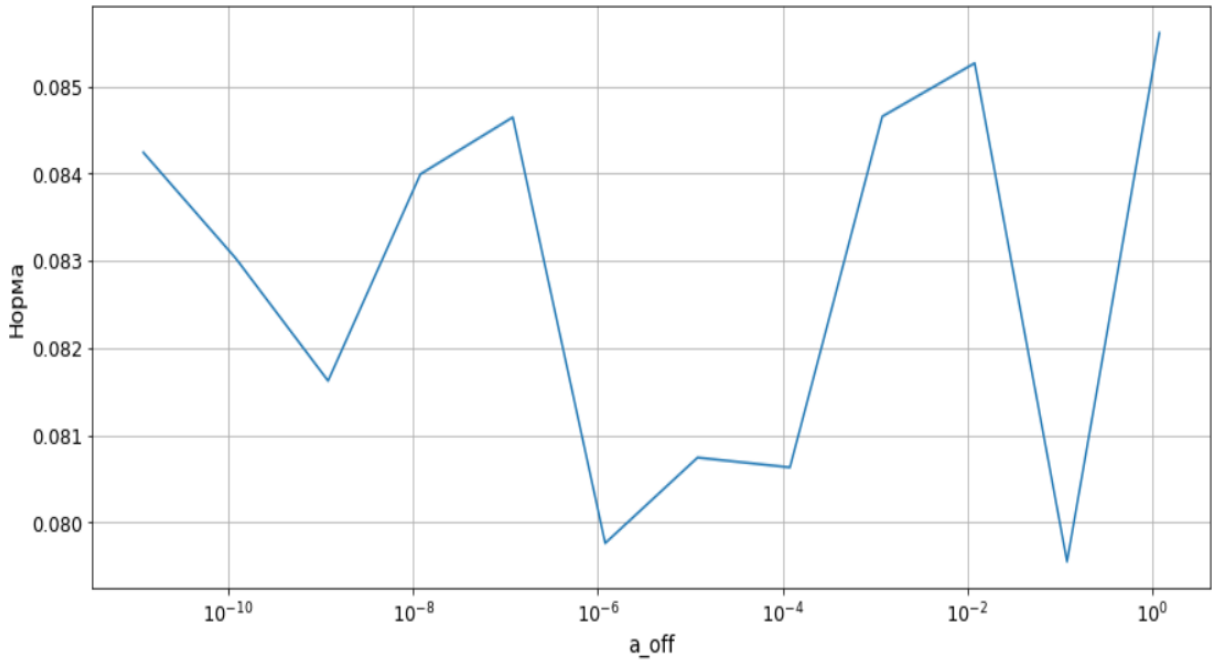

Рис. 3.7: Сходимость сети в зависимости от a_{off} . Норма вблизи значения 0,1 соответствует сходимости, норма, отличная от 0.1, соответствует расходимости.

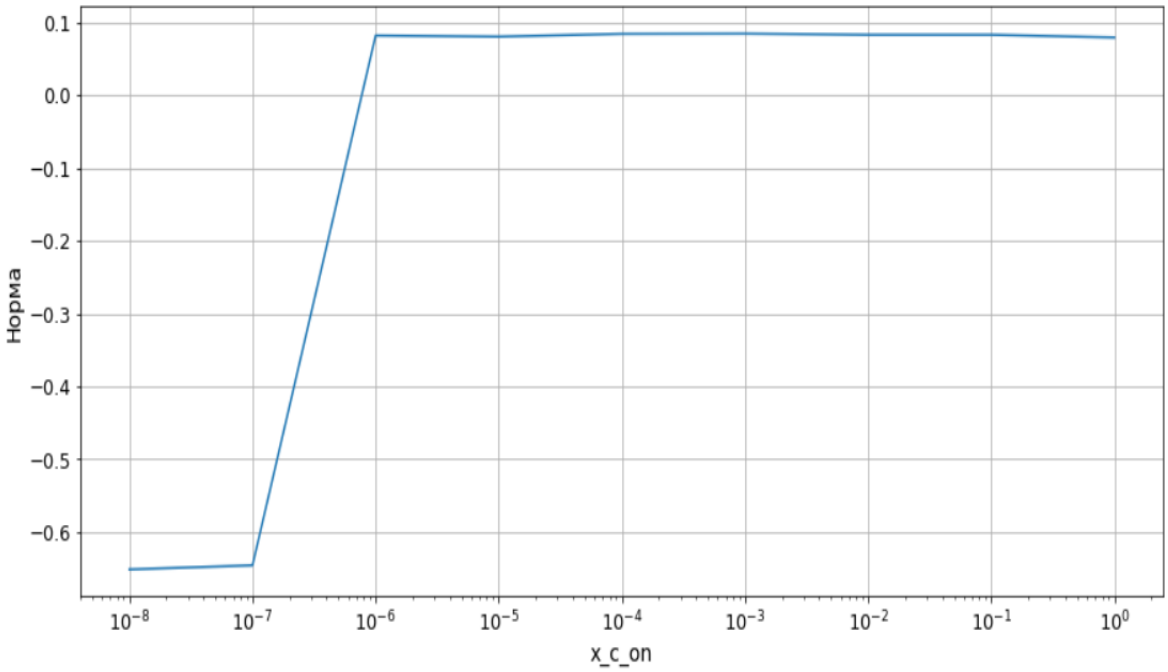

Рис. 3.8: Сходимость сети в зависимости от x_{c_on} . Норма вблизи значения 0,1 соответствует сходимости, норма, отличная от 0.1, соответствует расходимости.

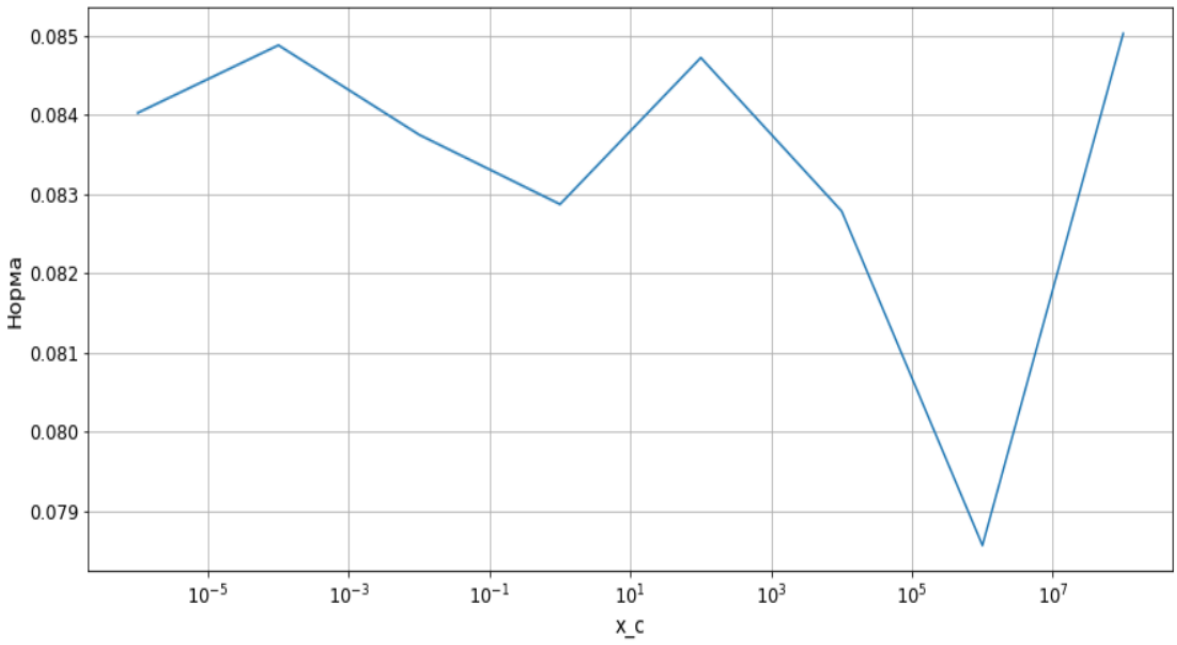

Рис. 3.9: Сходимость сети в зависимости от x_c . Норма вблизи значения 0,1 соответствует сходимости, норма, отличная от 0.1, соответствует расходимости. Были также отдельно промерены некоторые точки за пределами этого диапазона. Везде результат близок к 0.1 с незначительными флуктуациями.

Параметр VTEAM	Область сходимости
A_{on}	от 0 до 10
A_{off}	от 10 до ∞
K_{on}	от -10^{-7} до 0
K_{off}	от 0 до 10^{-5}
a_{on}	от 0 до 10^{-5}
a_{off}	при любых значениях
x_{c_on}	от 10^{-7} до ∞
x_c	при любых значениях

Выводы

В рамках данной работы:

1) Были рассмотрены различные математические модели мемристора и программно реализована модель VTEAM (Voltage ThrEshold Adaptive Model)

2) Были внесены изменения в библиотеку для симуляции импульсных нейронных сетей BindsNET. Добавлена возможность работы с битреугольными импульсами и поддержка правил обучения, задаваемых заранее построенными кривыми STDP

3) Были получены кривые STDP для модели VTEAM при прохождении битреугольных импульсов для каждого значения нормированной на 1 проводимости с шагом 0.01, соответствующие различным значениям параметров, входящих в VTEAM.

4) Были найдены границы областей значений параметров (по порядку величины), в которых сходимость тестовой НС воспроизводима. Параметры a_{off} и x_c, входящие в оконную функцию, призванную учесть границы устройства в случае превышения положительного порога напряжения, не влияют на сходимость, в то время как другие параметры, от которых зависит производная по времени от координаты границы легированного слоя устройства, существенно влияют на сходимость.

Заключение

Мемристоры, описываемые моделью с параметрами из найденных областей сходимости, являются перспективными для аппаратной реализации импульсной НС. Подобными параметрами обладают, например, физически реализованные мемристоры на основе нанокомпозитного материала LiNbO3:CoFe [20]. Полученные результаты предстоит проверить на импульсных сетях с более сложной архитектурой, чтобы исследовать возможность создания энергоэффективной самообучающейся нейроморфной вычислительной системы.

Благодарности

Выражаю благодарности Дёмину Вячеславу Александровичу за поддержку и руководство, Нехаеву Дмитрию Вадимовичу за неоценимую помощь на всех этапах работы, а также Суражевскому Игорю Алексеевичу за предоставленные данные и консультации.

Список использованных источников

1. R. Ananthanarayanan, S. K. Esser, H. D. Simon, and D. S. Modha, "The cat is out of the bag: cortical simulations with 109 neurons, 1013 synapses," in Proceedings of the Conference on High Performance Computing Networking, Storage and Analysis, SC '09, (New York, NY, USA), pp. 63:1–63:12, ACM, 2009.

2. J. Del Valle, J. G. Ramırez, M. J. Rozenberg, and I. K. Schuller, Journal of Applied Physics 124, 211101 (2018).

3. Davies et al, "Loihi: A Neuromorphic Manycore Processor with On-Chip Learning." IEEE Micro, Jan/Feb 2018.

4. F. Akopyan et al., "TrueNorth: Design and Tool Flow of a 65 mW 1 Million Neuron Programmable Neurosynaptic Chip" in IEEE Transactions on ComputerAided Design of Integrated Circuits and Systems. 2015, 34(10), pp. 1537 – 1557.

5. J. Schemmel, A. Grubl, K. Meier, E.Mueller, "Implementing Synaptic Plasticity in a VLSI Spiking Neural Network Model", Proceeding Int. Joint Conf. Neural Netw. 2006.

6. D. B. Strukov, G. S. Snider, D. R. Stewart, and R. S. Williams, The missing memristor found, Nature, 453, 80–83, 2008.

7. Y. Li, Z. Wang, R. Midya, Q. Xiaa, and J. J. Yang, Journal of Physics D: Applied Physics 51, 503002 (2018).

8. C. Ye, J. Wu, G. He, J. Zhang, T. Deng, P. He, and H. Wang, Journal of Materials Science and Technology 32, 1 (2016). 9. C. Li, J. Joshua Yang,

Q. Xia et al., “Analogue signal and image processing with large memristor crossbars”, Nature Electronics volume 1, pages52–59 (2018).

9. C. Li, J. Joshua Yang, Q. Xia et al., “Analogue signal and image processing with large memristor crossbars”, Nature Electronics volume 1, pages52–59 (2018).

10. P. Yao et al. “Face classifcation using electronic synapses”, Nat. Commun. 8, 15199 (2017).

11. T. Serrano-Gotarredona, T. Masquelier, T. Prodromakis, G. Indiveri, and B. LinaresBarranco, Frontiers in Neuroscience 7, 2 (2013).

12. A. V. Emelyanov, K. E. Nikiruy, V. A. Demin, V. V. Rylkov, A. I. Belov, D. S. Korolev, E. G. Gryaznov, D. A. Pavlov, O. N. Gorshkov, A. N. Mikhaylov, and P. Dimitrakis, Microelectronic Engineering 215, 110988 (2019).

13. Суражевский И. А., Рыльков В. В., Никируй К. Э., Емельянов А. В., Демин В. А., “Программные и аппаратные реализации основных компонент спайковых и формальных нейронных сетей”, Международный форум «Микроэлектроника-2019», г. Алушта, 30 сентября – 05 октября 2019 г.

14. *Chua L.O.* Memristor – the missing circuit element. / Chua L.O. // IEEE Trans. Circuit Theory, 1971, v.18, p.507–519.

15. V.A. Demin, V.V. Erokhin, “Hidden Symmetry Shows What a Memristor Is”, Int. Journ. of Unconventional Computing, Vol. 0, pp. 1–6 (2016).

16. Nikiruy KE, Emelyanov A V., Demin VA, Sitnikov AV, Minnekhanov AA, Rylkov V V., Kashkarov PK, Kovalchuk M V. 2019. Dopamine-like STDP modulation in nanocomposite memristors. AIP Adv 9:065116.

17. S. Kvatinsky et al., “VTEAM – A General Model for Voltage Controlled Memristors,” IEEE Transactions On Circuits And Systems—Ii: Express Briefs, Vol. 62, No. 8, August 2015.

18. M. D. Pickett, D. B. Strukov, J. L. Borghetti, J. J. Yang, G. S. Snider, D. R. Stewart, and R. S. Williams, “Switching dynamics in titanium dioxide memristive devices,” J. Appl. Phys., vol. 106, no. 7, pp. 1–6, Oct. 2009.

19. Hazan H, Saunders DJ, Khan H, Patel D(2018) BindsNET: A Machine Learning-Oriented Spiking Neural Networks Library in Python. //Front. Neuroinform. 12:89.

20. Rylkov V V., Nikolaev SN, Demin VA, Emelyanov A V., Sitnikov AV, Nikiruy KE, et al. 2018. Transport, Magnetic, and Memristive Properties of a Nanogranular (CoFeB)x(LiNbOy)100 – x Composite Material. J Exp Theor Phys 126(3):424–441

21. Maas, Wolfgang. Networks of spiking neurons: The third generation of neural network models (англ.) // Neural Networks : journal. — 1997. — Vol. 10. — P. 1659—1671

22. Wulfram Gerstner, Werner M. Kistler, Richard Naud and Liam Paninski, “Neuronal Dynamics”, Cambridge University Press, July 2014

23. S. Kvatinsky et al., “TEAM: ThrEshold Adaptive Memristor Model”, Transactions on circuits and systems - I: regular papers, vol.60, No. 1, january 2013.